

Mạng chú ý đồ thị không đồng nhất

Xiao Wang, Houye Ji Đại
học Bưu chính Viễn thông Bắc Kinh Bắc Kinh, Trung Quốc
{xiaowang, jhy1993} @ bupt.edu.cn

Peng Cui, P. Yu
Tsinghua University
Bắc Kinh, Trung
Quốc {cuip, psyu} @ tsinghua.edu.cn

Chuan Shi *, Bai Wang, Đại
học Bưu chính Viễn thông Bắc Kinh Bắc Kinh, Trung Quốc
{shichuan, wangbai} @ bupt.edu.cn

Đại học Yanfang
Ye West Virginia WV, Hoa
Kỳ
yanfang.ye@mail.wvu.edu

TRƯỜNG TƯỢNG

Mạng nơ-ron đồ thị, như một kỹ thuật biểu diễn đồ thị mạnh mẽ dựa trên học sâu, đã cho thấy hiệu suất vượt trội và thu hút được sự quan tâm nghiên cứu đáng kể. Tuy nhiên, nó vẫn chưa được xem xét đầy đủ trong mạng nơ-ron đồ thị đối với đồ thị không đồng nhất chứa các loại nút và liên kết khác nhau. Tính không đồng nhất và thông tin phong phú về ngữ nghĩa mang lại những thách thức lớn cho việc thiết kế một mạng nơ-ron đồ thị cho đồ thị không đồng nhất. Gần đây, một trong những tiến bộ thú vị nhất trong học sâu là cơ chế chú ý, tiềm năng to lớn của nó đã được chứng minh trong nhiều lĩnh vực khác nhau. Trong bài báo này, trước tiên chúng tôi đề xuất một mạng nơ-ron đồ thị không đồng nhất mới dựa trên sự chú ý phân cấp, bao gồm sự chú ý ở cấp độ nút và cấp độ ngữ nghĩa. Cụ thể, sự chú ý ở cấp độ nút nhằm mục đích tìm hiểu tầm quan trọng giữa một nút và các hàng xóm dựa trên đường dẫn meta của nó, trong khi sự chú ý ở cấp độ ngữ nghĩa có thể tìm hiểu tầm quan trọng của các đường dẫn meta khác nhau. Với tầm quan trọng đã học được từ cả sự chú ý ở cấp độ nút và cấp độ ngữ nghĩa, tầm quan trọng của nút và siêu đường dẫn có thể được xem xét đầy đủ. Sau đó, mô hình được đề xuất có thể tạo nút nhúng bằng cách tổng hợp các tính năng từ các hàng xóm dựa trên đường dẫn meta theo cách phân cấp.

Các kết quả thử nghiệm mở rộng trên ba đồ thị không đồng nhất trong thế giới thực không chỉ cho thấy hiệu suất vượt trội của mô hình được đề xuất của chúng tôi so với mô hình hiện đại, mà còn chứng minh khả năng diễn giải tốt của nó để phân tích đồ thị.

TỪ KHÓA

Mạng xã hội, Mạng thần kinh, Phân tích đồ thị

Định dạng tham chiếu

ACM: Xiao Wang, Houye Ji, Chuan Shi *, Bai Wang, Peng Cui, P. Yu và Yanfang Ye. 2019. Mạng chú ý đồ thị không đồng nhất. Trong Kỳ yếu WWW 2019, Jennifer B. Sartor, Theo D'Hondt và Wolfgang De Meuter (Eds.). ACM, New York, NY, USA, Điều 4, 11 trang. https://doi.org/10.475/123_4

1. GIỚI THIỆU

Dữ liệu trong thế giới thực thường đi kèm với biểu đồ cấu trúc, chẳng hạn như mạng xã hội, mạng trích dẫn và toàn thế giới

Được phép tạo bản sao kỹ thuật số hoặc bản in của một phần hoặc toàn bộ tác phẩm này để sử dụng cho mục đích cá nhân hoặc lớp học được cấp miễn phí với điều kiện các bản sao không được tạo ra hoặc phân phối vì lợi nhuận hoặc lợi thế thương mại và các bản sao phải có thông báo này và trích dẫn đầy đủ trên trang đầu tiên. Bản quyền cho các thành phần bên thứ ba của tác phẩm này phải được tôn trọng.

Đối với tất cả các mục đích sử dụng khác, hãy liên hệ với chủ sở hữu / (các) tác giả.
WWW 2019, tháng 5 năm 2019, San Francisco, Hoa Kỳ
© 2019 Bản quyền do chủ sở hữu / (các) tác giả nắm giữ.
ACM ISBN 123-4567-24-567 / 08/06.
https://doi.org/10.475/123_4


web. Mạng nơ-ron đồ thị (GNN), như một phương pháp học tation chuyên sâu mạnh mẽ cho dữ liệu đồ thị như vậy, đã cho thấy hiệu suất vượt trội về phân tích mạng và thu hút sự quan tâm nghiên cứu đáng kể. Ví dụ: [10, 20, 24] tận dụng mạng nơ-ron sâu để tìm hiểu các biểu diễn nút dựa trên các đặc điểm của nút và cấu trúc đồ thị. Một số công trình [6, 14, 18] đề xuất mạng chập đồ thị bằng cách tổng quát hóa phép toán chập thành đồ thị. Một xu hướng nghiên cứu gần đây trong học tập sâu là cơ chế chú ý, xử lý dữ liệu có kích thước thay đổi và khuyến khích mô hình tập trung vào những phần nổi bật nhất của dữ liệu. Nó đã chứng minh tính hiệu quả trong khuôn khổ mạng nơ-ron sâu và được áp dụng rộng rãi cho các ứng dụng khác nhau, chẳng hạn như phân tích văn bản [1], đồ thị tri thức [25] và xử lý hình ảnh [38]. Mạng chú ý đồ thị (GAT) [35], một mạng nơ-ron đồ thị kiểu tích chập mới, thúc đẩy cơ chế chú ý cho đồ thị đồng nhất chỉ bao gồm một loại nút hoặc liên kết.

Mặc dù sự thành công của cơ chế chú ý trong học sâu, nó vẫn chưa được xem xét trong khung mạng nơ-ron đồ thị cho đồ thị không đồng nhất. Trên thực tế, đồ thị trong thế giới thực usu ally đi kèm với nhiều loại nút và cạnh, còn được gọi rộng rãi là mạng thông tin không đồng nhất (HIN) [28]. Để thuận tiện, chúng tôi thống nhất gọi nó là đồ thị không đồng nhất trong bài báo này. Bởi vì đồ thị không đồng nhất chứa thông tin toàn diện hơn và ngữ nghĩa phong phú, nó đã được sử dụng rộng rãi trong nhiều nhiệm vụ khai thác dữ liệu. Meta-path [32], một quan hệ tổng hợp kết nối hai đối tượng, là một cấu trúc được sử dụng rộng rãi để nắm bắt ngữ nghĩa. Lấy dữ liệu phim IMDB1 trong Hình 1 (a) làm ví dụ, nó chứa ba loại nút bao gồm phim, diễn viên và đạo diễn. Mỗi quan hệ giữa hai phim có thể được tiết lộ bằng meta-path Movie-Actor-Movie (MAM) mô tả mối quan hệ đồng diễn viên, trong khi Phim-Đạo diễn-Phim (MDM) có nghĩa là chúng được chỉ đạo bởi cùng một đạo diễn. Như có thể thấy, tùy thuộc vào các đường dẫn meta, mối quan hệ giữa các nút trong đồ thị không đồng nhất có thể có ngữ nghĩa khác nhau. Do sự phức tạp của đồ thị không đồng nhất, mạng nơ-ron đồ thị truyền thống không thể được áp dụng trực tiếp cho đồ thị không đồng nhất.

Trên cơ sở phân tích ở trên, khi thiết kế kiến trúc mạng lưới thần kinh đồ thị với cơ chế chú ý đối với đồ thị không đồng nhất, chúng ta cần giải quyết các yêu cầu mới sau đây.

Tính không đồng nhất của đồ thị. Tính không đồng nhất là một lỗi hỗ trợ nội tại của đồ thị không đồng nhất, tức là, các loại nút và cạnh khác nhau. Ví dụ: các loại nút khác nhau có các đặc điểm khác nhau và các tính năng của chúng có thể nằm trong không gian đặc trưng khác nhau. Văn lấy IMDB làm

¹<https://www.imdb.com>



Hình 1: Ví dụ minh họa về đồ thị không đồng nhất (IMDB). (a) Ba loại nút (tức là, diễn viên, phim, đạo diễn). (b) Một đồ thị không đồng nhất IMDB bao gồm ba loại nút và hai loại kết nối. (c) Hai meta-path liên quan đến IMDB (tức là Moive-Actor-Movie và Movie-Director-Movie). (d)

Moive 1 và các hàng xóm dựa trên meta đường dẫn của nó (tức là, 1, 2 và 3).

ví dụ, đặc điểm của một diễn viên có thể liên quan đến giới tính, tuổi tác và quốc tịch. Mặt khác, đặc điểm của phim có thể liên quan đến cốt truyện và diễn viên. Làm thế nào để xử lý các thông tin cấu trúc phức tạp như vậy và bảo tồn đồng thời các thông tin đặc trưng đa dạng là một vấn đề cấp bách cần được giải quyết.

Chú ý ở cấp độ ngữ nghĩa. Các thông tin phức tạp và có ý nghĩa khác nhau có liên quan đến đồ thị không đồng nhất, thường được phản ánh bằng các đường dẫn tổng hợp [32]. Các đường dẫn meta khác nhau trong đồ thị không đồng nhất có thể trích xuất thông tin ngữ nghĩa đa dạng. Làm thế nào để chọn các đường dẫn meta có ý nghĩa nhất và kết hợp thông tin ngữ nghĩa cho nhiệm vụ cụ thể là một vấn đề mở [4, 19, 26].

Sự chú ý ở cấp độ ngữ nghĩa nhằm mục đích tìm hiểu tầm quan trọng của mỗi đường dẫn meta và chỉ định trọng số thích hợp cho chúng. Vẫn lấy IMDB làm ví dụ, The Terminator có thể kết nối với The Terminator 2 qua Movie-Actor-Movie (cả hai đều do Schwarzenegger thủ vai chính) hoặc kết nối với Birdy qua Movie-Year-Movie (cả hai đều quay vào năm 1984). Tuy nhiên, khi xác định thể loại phim Kế hủy diệt, MAM thường đóng vai trò quan trọng hơn là MYM. Do đó, việc xử lý các đường dẫn meta khác nhau như nhau là không thực tế và sẽ làm suy yếu thông tin được cung cấp bởi một số đường dẫn meta hữu ích.

Sự chú ý ở cấp độ nút. Trong một đồ thị không đồng nhất, các nút có thể được kết nối thông qua nhiều kiểu quan hệ khác nhau, ví dụ: đường dẫn meta. Với một đường dẫn meta, mỗi nút có rất nhiều hàng xóm dựa trên đường dẫn meta. Làm thế nào để phân biệt sự khác biệt tinh tế của những người hàng xóm và chọn một số neighbors có nhiều thông tin là cần thiết. Đối với mỗi nút, sự chú ý ở cấp độ nút nhằm mục đích tìm hiểu tầm quan trọng của các hàng xóm dựa trên đường dẫn meta và gán các giá trị chú ý khác nhau cho chúng. Vẫn lấy IMDB làm ví dụ, khi sử dụng meta-path Movie-Director-Movie (các phim có cùng một đạo diễn), Kế hủy diệt sẽ kết nối với Titanic và Kế hủy diệt 2 thông qua đạo diễn James Cameron. Đến

xác định rõ hơn thể loại của The Terminator là phim khoa học viễn tưởng, người mẫu nên chú ý đến The Terminator 2 hơn là Titanic. Vì vậy, làm thế nào để thiết kế một mô hình có thể phát hiện ra sự khác biệt tinh tế của những người hàng xóm và tìm hiểu trọng lượng của họ đúng cách sẽ được mong muốn.

Trong bài báo này, chúng tôi đề xuất một biểu đồ không đồng nhất mới . Mạng, có tên HAN, xem xét cả cấp độ nút và

sự chú ý ở cấp độ ngữ nghĩa. Đặc biệt, với các đặc điểm nút làm đầu vào, chúng tôi sử dụng ma trận chuyển đổi kiểu cụ thể để chiếu các loại đặc điểm nút khác nhau vào cùng một không gian. Sau đó, sự chú ý ở cấp độ nút có thể tìm hiểu các giá trị chú ý giữa các nút và

các hàng xóm dựa trên siêu đường dẫn của chúng, trong khi sự chú ý ở cấp độ ngữ nghĩa nhằm mục đích tìm hiểu các giá trị chú ý của các siêu đường dẫn khác nhau cho nhiệm vụ cụ thể trong biểu đồ không đồng nhất. Dựa trên các giá trị chú ý đã học về hai cấp độ, mô hình của chúng tôi có thể nhận được sự kết hợp tối ưu giữa các hàng xóm và nhiều đường dẫn meta theo cách thức phân cấp, cho phép những nút đã học để nắm bắt tốt hơn cấu trúc phức tạp và thông tin ngữ nghĩa phong phú trong một đồ thị không đồng nhất. Sau đó, mô hình tổng thể có thể được tối ưu hóa thông qua nhân giống ngược theo cách thức end-to-end.

Những đóng góp trong công việc của chúng tôi được tóm tắt như sau: • Theo hiểu biết tốt nhất của chúng tôi, đây là nỗ lực đầu tiên để nghiên cứu mạng nơ-ron đồ thị không đồng nhất dựa trên cơ chế chú ý. Công việc của chúng tôi cho phép áp dụng trực tiếp mạng nơ-ron đồ thị vào đồ thị không đồng nhất và tạo điều kiện thuận lợi hơn nữa cho các ứng dụng dựa trên đồ thị không đồng nhất. • Chúng tôi đề xuất một mạng lưới chú ý đồ thị không đồng nhất (HAN) mới bao gồm cả cấp độ nút và cấp độ ngữ nghĩa tại các dự kiến. Hưởng lợi từ sự quan tâm phân cấp như vậy, HAN được đề xuất có thể xem xét đồng thời tầm quan trọng của các nút và siêu đường dẫn . Hơn nữa, mô hình của chúng tôi có hiệu quả cao, với độ phức tạp tuyến tính liên quan đến số lượng các cặp nút dựa trên đường dẫn meta, có thể được áp dụng cho đồ thị không đồng nhất quy mô lớn. • Chúng tôi tiến hành các thí nghiệm rộng rãi để đánh giá hiệu suất của mô hình được đề xuất. Kết quả cho thấy tính ưu việt của mô hình tư thế chuyên nghiệp bằng cách so sánh với các mô hình hiện đại nhất. Quan trọng hơn, bằng cách phân tích cơ chế chú ý thứ bậc, HAN được đề xuất chứng tỏ khả năng diễn giải tốt của nó đối với phân tích đồ thị không đồng nhất.

2 CÔNG VIỆC LIÊN QUAN

2.1 Mạng nơ-ron biểu đồ Mạng nơ-ron biểu đồ

(GNN) nhằm mục đích mở rộng mạng nơ-ron sâu để xử lý dữ liệu có cấu trúc đồ thị tùy ý được giới thiệu trong [10, 24]. Yujia Li và cộng sự. [20] đề xuất một mô hình lan truyền có thể kết hợp các đơn vị định kỳ được kiểm soát để truyền thông tin trên tất cả các nút. Gần đây, có một sự gia tăng của hoạt động tích lũy tổng quát hóa trên dữ liệu có cấu trúc đồ thị. Công việc tích hợp của đồ thị neu ral thường được chia thành hai loại, đó là miền phổ và miền không phổ. Một mặt, các phương pháp tiếp cận quang phổ hoạt động với sự biểu diễn phổ của các đồ thị. Joan Bruna và cộng sự. [2] mở rộng tích chập thành đồ thị tổng quát bằng cách tìm cơ sở Fourier tương ứng. Michael và cộng sự. [6] sử dụng các đa danh mục Chebyshev bậc K để làm gần đúng các bộ lọc mịn trong miền quang phổ. Kipf và cộng sự. [18] đề xuất một phương pháp tiếp cận phổ, được đặt tên là Mạng màu biểu đồ Convolution , thiết kế một mạng tích chập đồ thị thông qua một phép xấp xỉ bậc nhất được bản địa hóa của các chập trùng đồ thị.

Mặt khác, chúng tôi cũng có các phương pháp tiếp cận không phổ, xác định độ chập chờn trực tiếp trên biểu đồ, hoạt động trên các nhóm láng giềng gần nhau. Hamilton và cộng sự. [14] giới thiệu GraphSAGE thực hiện bộ tổng hợp dựa trên mạng nơ-ron trên một hàng xóm nút có kích thước cố định. Nó có thể học một chức năng tạo những bằng cách tổng hợp các tính năng từ vùng lân cận cục bộ của nút.

Mạng chú ý đồ thị không đồng nhất

WWW 2019, tháng 5 năm 2019, San Francisco, Hoa Kỳ

Các cơ chế chú ý, ví dụ, tự chú ý [34] và chú ý mềm [1], đã trở thành một trong những cơ chế có ảnh hưởng nhất trong học sâu. Một số công trình trước đây giới thiệu cơ chế chú ý cho các ứng dụng dựa trên đồ thị, ví dụ, khuyến nghị [15, 16].

Lấy cảm hứng từ cơ chế chú ý, Mạng Chú ý Đồ thị [35] được đề xuất để tìm hiểu tầm quan trọng giữa các nút và các nút lân cận của nó và kết hợp các nút lân cận để thực hiện phân loại nút. Tuy nhiên, mạng nơron đồ thị trên không thể xử lý các loại nút và cạnh khác nhau và chỉ có thể áp dụng cho các đồ thị thuần nhất.

2.2 Nhúng mạng Nhúng mạng, tức là học biểu

diễn mạng (NRL), được đề xuất để nhúng mạng vào một không gian chiều thấp trong khi vẫn bảo toàn cấu trúc và thuộc tính mạng để các phép nhúng đã học có thể được áp dụng cho các tác vụ mạng hạ lưu. Ví dụ, các phương pháp dựa trên bước đi ngẫu nhiên [12, 23], các phương pháp dựa trên mạng nơron sâu [36], các phương pháp dựa trên thừa số hóa ma trận [22, 37] và các phương pháp khác, ví dụ: LINE [33]. Tuy nhiên, tất cả các thuật toán này được đề xuất cho các đồ thị thuần nhất. Một số đánh giá công phu có thể được tìm thấy trong [5, 11].

Những đồ thị không đồng nhất chủ yếu tập trung vào việc bảo toàn thông tin cấu trúc dựa trên đường dẫn meta. ESim [26] chấp nhận các siêu đường dẫn do người dùng xác định làm hướng dẫn để tìm hiểu vectơ đỉnh trong không gian nhúng được người dùng ưa thích để tìm kiếm sự tương tự. Ngay cả thông qua ESim có thể sử dụng nhiều đường dẫn meta, nó không thể học được tầm quan trọng của đường dẫn meta. Để đạt được hiệu suất tốt nhất, ESim cần tìm kiếm lưới ống dẫn để tìm trọng lượng tối ưu của đường dẫn hmeta. Khá khó để tìm ra sự kết hợp tối ưu cho nhiệm vụ cụ thể. Meta path2vec [7] thiết kế một lối đi ngẫu nhiên dựa trên meta-path và sử dụng hàm bỏ qua để thực hiện nhúng đồ thị không đồng nhất. Tuy nhiên, metapath2vec chỉ có thể sử dụng một meta-path và có thể bỏ qua một số thông tin hữu ích. Tương tự như metapath2vec, HERec [27] đề xuất một chiến lược ràng buộc kiểu để lọc chuỗi nút và nắm bắt ngữ nghĩa phức tạp được phản ánh trong đồ thị không đồng nhất. HIN2Vec [9] thực hiện nhiều nhiệm vụ đào tạo dự đoán đồng thời học các vectơ la lều của các nút và đường dẫn meta. Chen và cộng sự. [3] đề xuất một mô hình nhúng số liệu dự kiến, được đặt tên là PME, có thể duy trì các điểm gần nút thông qua Khoảng cách Euclidian. PME chiếu các loại nút khác nhau vào cùng một không gian quan hệ và tiến hành dự đoán liên kết không đồng nhất. Để nghiên cứu vấn đề comprehen sive mô tả đồ thị không đồng nhất, Chen et al. [29] đề xuất HEER có thể nhúng đồ thị không đồng nhất thông qua các biểu diễn cạnh. Fan và cộng sự. [8] đề xuất mô hình nhúng metagraph2vec, trong đó cả cấu trúc và ngữ nghĩa đều được bảo toàn tối đa để phát hiện phần mềm độc hại. Sun và cộng sự. [30] đề xuất mô hình dینگ nhúng mạng dựa trên đồ thị meta , mô hình này đồng thời xem xét các quan hệ ẩn của tất cả thông tin meta của một biểu đồ meta. Tóm lại, tất cả các thuật toán được đề cập ở trên không xem xét cơ chế chú ý trong học biểu diễn đồ thị không đồng nhất.

3 CHÍNH

Đồ thị không đồng nhất là một loại mạng thông tin đặc biệt, chứa nhiều loại đối tượng hoặc nhiều loại liên kết.

Định nghĩa 3.1. Đồ thị không đồng nhất [31]. Một đồ thị không đồng nhất, được ký hiệu là $G = (V, E)$, bao gồm một tập đối tượng V và một liên kết

tập E . Một đồ thị không đồng nhất cũng được liên kết với một hàm ánh xạ loại nút : $V \rightarrow A$ và một hàm ánh xạ loại liên kết : $E \rightarrow R$. A và R biểu thị các tập hợp các loại đối tượng được xác định trước và các loại liên kết, trong đó $|A| + |R| > 2$.

Thí dụ. Như trong Hình 1 (a), chúng tôi xây dựng một đồ thị không đồng nhất để mô hình IMDB. Nó bao gồm nhiều loại đối tượng (Diễn viên (A), Phim (M), Đạo diễn (D)) và quan hệ (quan hệ quay phim giữa phim và đạo diễn, quan hệ nhập vai giữa diễn viên và phim).

Trong đồ thị không đồng nhất, hai đối tượng có thể được kết nối thông qua các đường dẫn ngữ nghĩa khác nhau, được gọi là đường dẫn meta.

Định nghĩa 3.2. Siêu đường dẫn [32]. Siêu đường dẫn Φ được định nghĩa là đường dẫn ở dạng $1 \rightarrow 2 \rightarrow \dots \rightarrow n + 1$ (viết tắt như $1 \rightarrow 2 \rightarrow \dots \rightarrow n + 1$), mô tả quan hệ tổng hợp $= 2 \rightarrow \dots \rightarrow n$ giữa các đối tượng 1 và trong đó biểu thị toán tử tổng hợp trên quan hệ.

Thí dụ. Như trong Hình 1 (a), hai phim có thể được kết nối qua nhiều đường dẫn meta, ví dụ: Phim-Diễn viên-Phim (MAM) và Phim-Đạo diễn-Phim (MDM). Các đường dẫn meta khác nhau luôn tiết lộ các ngữ nghĩa khác nhau. Ví dụ: MAM có nghĩa là quan hệ đồng diễn viên, trong khi Phim-Đạo diễn-Phim (MDM) có nghĩa là chúng được chỉ đạo bởi cùng một đạo diễn.

Với một đường dẫn meta Φ , tồn tại một tập hợp các boirs lân cận dựa trên đường dẫn meta của mỗi nút có thể tiết lộ thông tin cấu trúc đa dạng và ngữ nghĩa phong phú trong một biểu đồ không đồng nhất.

Định nghĩa 3.3. Hàng xóm dựa trên meta-đường dẫn. Given một nút và một đường dẫn meta Φ trong một đồ thị không đồng nhất, các hàng xóm dựa trên đường dẫn meta N_Φ của nút được định nghĩa là tập hợp các nút kết nối với nút thông qua đường dẫn meta Φ . Lưu ý rằng các hàng xóm của nút bao gồm chính nó.

Thí dụ. Lấy Hình 1 (d) làm ví dụ, dựa trên meta-path Movie-Actor-Movie, các hàng xóm dựa trên meta-path của 1 bao gồm 1 (chính nó), 2 và 3. Tương tự, các hàng xóm của 1 dựa trên meta-path Movie-Director-Movie bao gồm 1 và 2. Rõ ràng, các hàng xóm dựa trên meta-path có thể khai thác các khía cạnh khác nhau của thông tin cấu trúc trong đồ thị không đồng nhất. Chúng ta có thể nhận được các hàng xóm dựa trên đường dẫn meta bằng cách nhân một chuỗi các ma trận kề.

Mạng nơron đồ thị đã được đề xuất để xử lý dữ liệu có cấu trúc đồ thị tùy ý. Tuy nhiên, tất cả chúng đều được thiết kế cho mạng đồng nhất [18, 35]. Vì các hàng xóm dựa trên meta-path và meta-path là hai cấu trúc cơ bản trong một biểu đồ không đồng nhất, nên tiếp theo, chúng tôi sẽ trình bày một mạng nơron biểu đồ môi cho dữ liệu biểu đồ không đồng nhất, có thể khai thác sự khác biệt nhỏ của các nút và meta-path. Các ký hiệu mà chúng tôi sẽ sử dụng trong suốt bài viết được tóm tắt trong Bảng 1.

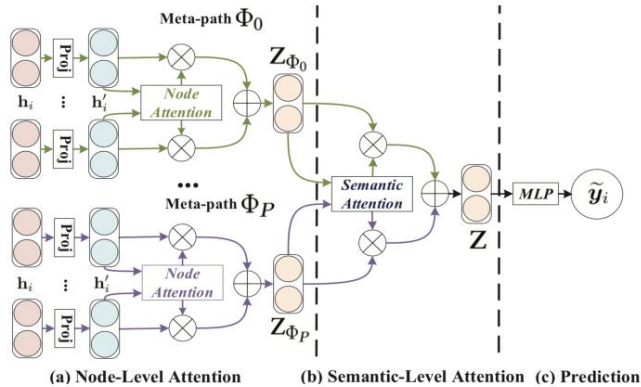
4 MÔ HÌNH ĐƯỢC ĐỀ XUẤT

Trong phần này, chúng tôi đề xuất một mạng nơron đồ thị bán giám sát mới cho đồ thị không đồng nhất. Mô hình của chúng tôi tuân theo cấu trúc chú ý phân cấp: chú ý cấp nút chú ý cấp ngữ nghĩa.

Hình 2 trình bày toàn bộ khuôn khổ của HAN. Đầu tiên, chúng tôi đề xuất sự chú ý ở cấp độ nút để tìm hiểu trọng lượng của các hàng xóm dựa trên đường dẫn meta và tổng hợp chúng lại để có được việc nhúng nút cụ thể theo ngữ nghĩa.

Bảng 1: Ký hiệu và Giải thích.

Ký hiệu	Giải trình
Φ	Meta-path
h	Tính năng nút ban đầu
M	Ma trận chuyển đổi loại cụ thể
g	Tính năng nút dự kiến
Φ	Tầm quan trọng của cặp nút dựa trên đường dẫn meta (.)
$a\Phi$	Vectơ chú ý cấp nút cho siêu đường dẫn Φ
Φ	Trọng số của cặp nút dựa trên đường dẫn meta (.)
$N\Phi$	Hàng xóm dựa trên đường dẫn meta
$Z\Phi$	Những nút theo ngữ nghĩa cụ thể
q	Véc tơ chú ý cấp ngữ nghĩa
Φ	Tầm quan trọng của meta-path Φ
Φ	Trọng lượng của meta-path Φ
Z	Những cuối cùng



Hình 2: Khung tổng thể của HAN đề xuất. (a) Tất cả các loại nút được chiếu vào một không gian tính năng thống nhất và trọng số của cặp nút dựa trên đường dẫn meta có thể được học thông qua sự chú ý ở cấp độ nút. (b) Học chung trọng lượng của mỗi meta-path và kết hợp những nút theo ngữ nghĩa cụ thể thông qua sự chú ý ở cấp độ ngữ nghĩa. (c) Tính toán tổn thất và tối ưu hóa đầu cuối cho HAN được đề xuất.

Sau đó, HAN có thể cho biết sự khác biệt của các đường dẫn meta thông qua sự chú ý ở cấp độ ngữ nghĩa và nhận được sự kết hợp có trọng số tối ưu của những nút ngữ nghĩa cụ thể cho nhiệm vụ cụ thể.

4.1 Chú ý mức nút

Trước khi tổng hợp thông tin từ các hàng xóm siêu đường dẫn cho mỗi nút, chúng ta nên nhận thấy rằng các hàng xóm dựa trên đường dẫn meta của mỗi nút đóng một vai trò khác nhau và thể hiện tầm quan trọng khác nhau trong học những nút cho nhiệm vụ cụ thể. Ở đây chúng tôi giới thiệu sự chú ý ở cấp độ nút có thể tìm hiểu tầm quan trọng của việc dựa trên đường dẫn meta hàng xóm cho mỗi nút trong một đồ thị không đồng nhất và tổng hợp sự đại diện của những hàng xóm có ý nghĩa này để tạo thành một nút những.

Do tính không đồng nhất của các nút, các loại nút khác nhau có các không gian đặc trưng khác nhau. Do đó, đối với mỗi loại nút (ví dụ: nút

với kiểu), chúng tôi thiết kế ma trận chuyển đổi theo kiểu cụ thể M để chiếu các tính năng của các loại nút khác nhau vào cùng một không gian đặc trưng. Không giống như [13], ma trận biến đổi kiểu cụ thể dựa trên kiểu nút chứ không phải kiểu cạnh. Quá trình chiếu có thể được hiển thị như sau:

$$h' = M \cdot h, \tag{1}$$

Ở đây h và h' là đặc điểm gốc và đặc điểm dự kiến của nút tương ứng. Bằng hoạt động chiếu theo loại cụ thể, mức nút chú ý có thể xử lý các loại nút tùy ý.

Sau đó, chúng tôi tận dụng sự chú ý của bản thân [34] để tìm hiểu trọng lượng trong số các loại nút khác nhau. Cho một cặp nút $(,)$ là được kết nối thông qua meta-path Φ , sự chú ý ở cấp độ nút có thể tìm hiểu tầm quan trọng có nghĩa là nút quan trọng như thế nào đối với nút Tầm quan trọng của cặp nút dựa trên đường dẫn meta $(,)$ có thể là công thức như sau:

$$\Phi = (h', h'; \Phi). \tag{2}$$

Đây biểu thị mạng nơron sâu thực hiện là sự chú ý ở cấp độ nút. Đã cho meta-path Φ , được chia sẻ cho tất cả các cặp nút dựa trên đường dẫn meta. Đó là bởi vì có một số tương tự các mẫu kết nối theo một đường dẫn meta. Phương trình trên. (2) cho thấy meta-path đã cho Φ , trọng số của cặp nút dựa trên meta-path $(,)$ phụ thuộc vào các tính năng của chúng. Xin lưu ý rằng, không đối xứng, tức là, tầm quan trọng của nút đối với nút và tầm quan trọng của nút đối với nút có thể khá khác biệt. Nó cho thấy sự chú ý ở cấp độ nút có thể bảo tồn tính bất đối xứng vốn là đặc tính quan trọng của tính không đồng nhất đồ thị.

Sau đó, chúng tôi đưa thông tin cấu trúc vào mô hình thông qua sự chú ý được che đầy có nghĩa là chúng tôi chỉ tính Φ cho các nút

$N\Phi$, toán nơi $N\Phi$ biểu thị các hàng xóm dựa trên đường dẫn meta của nút (bao gồm chính nó). Sau khi nhận được tầm quan trọng giữa meta-path các cặp nút dựa trên, chúng tôi chuẩn hóa chúng để có được hệ số trọng số Φ thông qua chức năng softmax:

$$\Phi = (\Phi) = \frac{\exp(a\Phi \cdot [h' h])}{\sum_i N\Phi \exp(a\Phi \cdot [h' h])}, \tag{3}$$


trong đó biểu thị chức năng kích hoạt, biểu thị kết nối hoạt động và $a\Phi$ là vectơ chú ý mức nút cho siêu đường Φ . Như chúng ta có thể thấy từ Eq. (3), hệ số trọng số của $(,)$ phụ thuộc về các tính năng của chúng. Cũng xin lưu ý rằng hệ số trọng lượng là Φ không đối xứng có nghĩa là chúng đóng góp khác nhau cho mỗi khác. Không chỉ vì thứ tự nối trong tử số, mà cũng bởi vì họ có những người hàng xóm khác nhau nên thuật ngữ bình thường hóa (mẫu số) sẽ khá khác biệt.

Sau đó, việc những nút dựa trên đường dẫn meta có thể được tổng hợp bởi các tính năng dự kiến của hàng xóm với các hệ số như sau:

$$Z^\Phi = \Phi \cdot h'. \tag{4}$$

Z đầu Φ là cách những đã học của nút cho siêu đường dẫn Φ . Để hiểu rõ hơn về quy trình tổng hợp ở cấp độ nút, chúng tôi cũng giải thích ngắn gọn trong Hình 3 (a). Mỗi nút những là

Mạng chú ý đồ thị không đồng nhất



Hình 3: Giải thích quá trình tổng hợp ở cả cấp độ nút và cấp độ ngữ nghĩa.

tổng hợp bởi neighbors của nó. Vì trọng số chú ý được tính theo giới tính đối với một đường dẫn siêu đơn, nên nó có ngữ nghĩa cụ thể và có thể giải thích một loại thông tin ngữ nghĩa.

Vì đồ thị không đồng nhất trình bày thuộc tính không có tỷ lệ, phương sai của dữ liệu đồ thị khá cao. Để giải quyết thách thức trên, chúng tôi mở rộng sự chú ý ở cấp độ nút thành sự chú ý đa đầu để

quá trình đào tạo ổn định hơn. Cụ thể, chúng tôi lặp lại sự chú ý ở cấp độ nút trong thời gian và nối các lần nhúng đã học

dưới dạng nhúng theo ngữ nghĩa cụ thể:

$$z^{\Phi} = \frac{1}{N^{\Phi}} \sum_{i=1}^{N^{\Phi}} z_i^{\Phi} \cdot H^{\Phi} \quad (5)$$

Cho tập hợp đường dẫn meta $\{\Phi_1, \dots, \Phi_k\}$, sau khi cung cấp các tính năng của nút chú ý ở cấp độ nút, chúng ta có thể có được các nhóm về ngữ nghĩa cụ thể nhúng nút, được ký hiệu là $Z^{\Phi_1}, \dots, Z^{\Phi_k}$.

4.2 Chú ý ở cấp độ ngữ nghĩa

Nói chung, mọi nút trong một biểu đồ không đồng nhất chứa nhiều các loại thông tin ngữ nghĩa và định nhúng nút theo ngữ nghĩa cụ thể chỉ có thể phản ánh nút từ một khía cạnh. Để tìm hiểu cách nhúng nút phức tạp hơn, chúng ta cần kết hợp nhiều ngữ nghĩa mà có thể được tiết lộ bằng các đường dẫn meta. Để giải quyết thách thức của lựa chọn siêu đường dẫn và kết hợp ngữ nghĩa trong một biểu đồ không đồng nhất, chúng tôi đề xuất một sự chú ý ở cấp độ ngữ nghĩa mới để tự động học tầm quan trọng của các đường dẫn meta khác nhau và kết hợp chúng cho nhiệm vụ cụ thể. Lấy các nhóm nhúng nút theo ngữ nghĩa cụ thể đã học được từ sự chú ý ở cấp độ nút làm đầu vào, các trọng số đã học của mỗi meta-path (Φ_1, \dots, Φ_k) có thể được hiển thị như sau:

$$(\Phi_1, \dots, \Phi_k) = (Z^{\Phi_1}, \dots, Z^{\Phi_k}). \quad (6)$$

Nơi đây biểu thị mạng nơron sâu thực hiện sự chú ý ở cấp độ ngữ nghĩa. Nó cho thấy rằng sự chú ý ở cấp độ ngữ nghĩa có thể nắm bắt các loại thông tin ngữ nghĩa khác nhau đằng sau một biểu đồ chung khác nhau.

Để tìm hiểu tầm quan trọng của mỗi meta-path, trước tiên chúng tôi chuyển đổi nhúng theo ngữ nghĩa cụ thể thông qua một phép chuyển đổi phi tuyến tính (ví dụ: MLP một lớp). Sau đó, chúng tôi đo lường tầm quan trọng của

WWW 2019, tháng 5 năm 2019, San Francisco, Hoa Kỳ

nhúng theo ngữ nghĩa cụ thể như sự giống nhau của bộ đồ giường em đã được biến đổi với vectơ chú ý mức ngữ nghĩa q. Hơn nữa, chúng tôi tính trung bình tầm quan trọng của tất cả các nút nhúng theo ngữ nghĩa cụ thể mà có thể được giải thích là tầm quan trọng của mỗi meta-path. Các tầm quan trọng của mỗi meta-path, được ký hiệu là Φ , được hiển thị như sau:

$$\Phi = \frac{1}{|V|} \sum_{q \in V} q^T \cdot \text{Tanh}(W \cdot z + b), \quad (7)$$

trong đó W là ma trận trọng số, b là vectơ thiên vị, q là vectơ chú ý mức ngữ nghĩa. Lưu ý rằng để so sánh có ý nghĩa, tất cả các thông số trên được chia sẻ cho tất cả các siêu đường dẫn và ngữ nghĩa cụ thể nhúng. Sau khi hiểu được tầm quan trọng của từng meta đường dẫn, chúng tôi chuẩn hóa chúng thông qua chức năng softmax. Trọng số của meta-path Φ được ký hiệu là Φ , có thể nhận được bằng cách chuẩn hóa tầm quan trọng ở trên

của tất cả các đường dẫn meta bằng cách sử dụng hàm softmax,

$$\Phi = \frac{\exp(\Phi)}{\sum_{i=1}^k \exp(\Phi_i)}, \quad (\text{số 8})$$

có thể được hiểu là sự đóng góp của meta-path Φ cho nhiệm vụ cụ thể. Rõ ràng, Φ càng cao, càng quan trọng meta-path Φ là. Lưu ý rằng đối với các tác vụ khác nhau, meta-path Φ có thể có trọng lượng khác nhau. Với các trọng số đã học dưới dạng hệ số, chúng ta có thể kết hợp các nhúng theo ngữ nghĩa cụ thể này để có được kết quả cuối cùng nhúng Z như sau:

$$Z = \sum_{i=1}^k \Phi_i \cdot Z^{\Phi_i}. \quad (9)$$

Để hiểu rõ hơn về quá trình tổng hợp ở cấp độ ngữ nghĩa, chúng tôi cũng giải thích ngắn gọn trong Hình 3 (b). Nhúng cuối cùng được tổng hợp bởi tất cả các nhúng theo ngữ nghĩa cụ thể. Sau đó chúng ta có thể áp dụng cách nhúng cuối cùng cho các nhiệm vụ cụ thể và thiết kế các tổn thất khác nhau fuction. Đối với phân loại nút bán giám sát, chúng tôi có thể giảm thiểu Cross-Entropy trên tất cả các nút được gắn nhãn giữa sự thật cơ bản và dự đoán:

$$L = - \sum_{Y \in \mathcal{Y}} Y \ln(C \cdot Z), \quad (10)$$

trong đó C là tham số của bộ phân loại, Y là tập hợp các nút chỉ số có nhãn, Y và Z là nhãn và nhúng của các nút có nhãn. Với hướng dẫn về dữ liệu được gắn nhãn, chúng tôi có thể tối ưu hóa mô hình được đề xuất thông qua tuyến truyền ngược và học cách nhúng của điểm giao. Quá trình tổng thể của HAN được thể hiện trong Thuật toán 1.

4.3 Phân tích mô hình đề xuất

Ở đây chúng tôi đưa ra phân tích về HAN được đề xuất như sau:

- Mô hình được đề xuất có thể xử lý các loại nút khác nhau và quan hệ và kết hợp ngữ nghĩa phong phú trong một đồ thị không đồng nhất. Thông tin có thể chuyển từ một loại nút này sang một loại nút khác thông qua quan hệ đa dạng. Được hưởng lợi từ một biểu đồ không đồng nhất như vậy mạng chú ý, các loại nhúng nút khác nhau có thể nâng cao sự hội nhập lẫn nhau, thúc đẩy lẫn nhau và nâng cấp lẫn nhau.
- HAN được đề xuất có hiệu quả cao và có thể dễ dàng phân bổ ngang bằng. Việc tính toán sự chú ý có thể tính toán riêng lẻ trên tất cả các nút và đường dẫn meta. Cho một đường dẫn meta Φ , thời gian com tính phức tạp của sự chú ý ở cấp độ $(\Phi_1 2 + \Phi_1)$, ở đâu nút là số lượng đầu chú ý, Φ là số lượng nút, Φ là

Bảng 2: Thống kê các bộ dữ liệu.

Mối quan hệ	tập dữ liệu (AB)	Số lượng A	Số lượng B	Số lượng bài kiểm tra	xác thực đào tạo tính	năng AB Siêu	đường dẫn			
DBLP	Giấy-Tác giả	14328	19645	4057		334	800	400	2857	APA
	Giấy-Conf	14328	14328	14327	884220					APCPA
	Thời hạn giấy			8789						APTPA
IMDB	Diễn viên điện ảnh	4780		5841	14340	1232	300	300	2687	MAM
	Đạo diễn phim	4780		2269	4780					MDM
ACM	Giấy-Tác giả	3025		5835	9744	1830	600	300	2125	PAP
	Chủ đề giấy	3025		56	3025					PSP

Thuật toán 1: Quá trình tổng thể của HAN.	
Đầu vào :	Đồ thị không đồng nhất G = (V, E), Tính năng nút {h, V}, Tập hợp siêu đường dẫn {Φ0, Φ1, . . . , Φ}. Số lượng đầu chú ý Đầu ra : Những , cuối cùng Z Trọng lượng chú ý ở cấp độ nút, Trọng số chú ý ở cấp độ ngữ nghĩa.
1 cho Φ	{Φ0, Φ} làm
2 Φ1, . . . cho = 1 . . . làm	,
3	Chuyển đổi loại cụ thể h M · h;
4 cho V làm	
5	Tìm các hàng xóm dựa trên meta-đường dẫn NΦ ;
6 cho NΦ làm	Φ ;
7	Tính hệ số khối lượng
..	chấm dứt
9	Tính toán nhúng nút theo ngữ nghĩa cụ thể z Φ Φ · H ;
10	chấm dứt
11	Kết hợp các cách nhúng đã học từ tất cả đầu chú ý z Φ Φ · H ; = 1 Í NΦ
12 kết thúc	
13	Tính trọng số của meta đường Φ ;
14	Hợp nhất nhúng theo ngữ nghĩa cụ thể z Í = 1 Φ · ZΦ ;
15 kết thúc	
16	Tính Entropy chéo = - Í Y Y ln (C · Z);
17	Truyền ngược và cập nhật các tham số trong HAN;
18	trở lại , , .

số cặp nút dựa trên đường dẫn meta, 1 và 2 là số các hàng và cột của ma trận chuyển đổi, tương ứng. Các độ phức tạp tổng thể tuyến tính với số lượng nút và siêu đường dẫn các cặp nút dựa trên. Mô hình được đề xuất có thể dễ dàng song song hóa, bởi vì sự chú ý ở cấp độ nút và cấp độ ngữ nghĩa có thể được phân chia theo từng đường dẫn tương ứng trên các đường dẫn meta và meta của nút. Tổng thể độ phức tạp là tuyến tính với số lượng nút và dựa trên đường dẫn meta các cặp nút.

• Sự chú ý theo thứ bậc được chia sẻ cho toàn bộ không đồng nhất biểu đồ có nghĩa là số lượng tham số không phụ thuộc vào tỷ lệ của một đồ thị không đồng nhất và có thể được sử dụng để quy nạp các vấn đề [14]. Ở đây quy nạp có nghĩa là mô hình có thể tạo ra nút nhúng cho các nút chưa thấy trước đó hoặc thậm chí là biểu đồ chưa nhìn thấy.

• Mô hình đề xuất có khả năng diễn giải tốt về cách nhúng nút đã học là một lợi thế lớn cho phân tích đồ thị khác nhau. Với tầm quan trọng đã học được của các nút và meta-path, mô hình được đề xuất có thể chú ý nhiều hơn đến một số các nút hoặc đường dẫn meta có ý nghĩa cho nhiệm vụ cụ thể và cung cấp thêm mô tả chuyên sâu về một đồ thị không đồng nhất. Dựa vào giá trị chú ý, chúng tôi có thể kiểm tra các nút hoặc đường dẫn meta nào làm cho đóng góp cao hơn (hoặc thấp hơn) cho nhiệm vụ của chúng tôi, có lợi cho phân tích và giải thích kết quả của chúng tôi.

5 THÍ NGHIỆM

5.1 Bộ dữ liệu

Các mô tả chi tiết của đồ thị không đồng nhất được sử dụng ở đây là được thể hiện trong Bảng 2.

• DBLP2 . Chúng tôi trích xuất một tập hợp con của DBLP chứa 14328 pa pers (P), 4057 tác giả (A), 20 hội nghị (C), 8789 điều khoản (T). Các các tác giả được chia thành bốn lĩnh vực: cơ sở dữ liệu, khai thác dữ liệu, máy học tập, truy xuất thông tin. Ngoài ra, chúng tôi gán nhãn nghiên cứu của từng tác giả là các phần tử của một nhóm từ được thể hiện bằng các từ khóa. Nơi đây chúng tôi sử dụng tập hợp đường dẫn meta {APA, APCPA, APTPA} để thực hiện các thí nghiệm.

• ACM3 . Chúng tôi trích xuất các bài báo được xuất bản trong KDD, SIGMOD, SIG COMM, Mobicomm và VLDB và chia các bài báo thành ba các lớp (Cơ sở dữ liệu, Truyền thông không dây, Khai thác dữ liệu). sau đó chúng tôi xây dựng một biểu đồ không đồng nhất bao gồm 3025 giấy tờ (P), 5835 tác giả (A) và 56 chủ thể (S). Các tính năng của giấy tương ứng với các yếu tố của một nhóm từ được đại diện cho các từ khóa. Chúng tôi sử dụng tập hợp meta-path {PAP, PSP} để thực hiện các thử nghiệm. Ở đây chúng tôi gán nhãn các bài báo theo hội nghị mà họ đã xuất bản.

• IMDB. Ở đây chúng tôi trích xuất một tập hợp con của IMDB chứa 4780 phim (M), 5841 diễn viên (A) và 2269 đạo diễn (D). Những bộ phim được chia thành ba lớp (Hành động, Hài kịch, Chính kịch) theo thể loại của họ. Các tính năng của phim tương ứng với các yếu tố của một túi từ được đại diện cho các âm mưu. Chúng tôi sử dụng tập hợp đường dẫn meta {MAM, MDM} để thực hiện các thí nghiệm.

²<https://dblp.uni-trier.de>
³<http://dl.acm.org/>

Bảng 3: Kết quả định lượng (%) về nhiệm vụ phân loại nút.

Datasets	Metrics	Đào tạo	DeepWalk	ESim	metapath2vec	HERec	GCN	GAT	HAN	HAN	HAN						
ACM	Macro-F1	20%		77,25	77,32	65,09	66,17	86,81	86,23	89,40				88,15	89,04		
		40%		80,47	80,12	69,93	70,89	87,68	87,04	89,79				88,41	89,41		
		60%		82,55	82,44	71,47	72,38	88,10	87,56	89,51				87,91	90,00		
		80%		84,17	83,00	73,81	73,92	88,29	87,33	90,63				88,48	90,17		
	Micro-F1	20%		76,92	76,89	65,00	66,03	86,77	86,01	89,22				87,99	88,85		
		40%		79,99	79,70	69,75		70,73	87,64	86,79	72,24			88,31	89,27	89,64	
		60%		82,11	82,02	71,29		88,12	87,40					87,68	89,85	89,33	
		80%		83,88	82,89	73,69		73,84	88,35	87,11				88,26	89,95	90,54	
DBLP	Macro-F1	20%		77,43	91,64	90,16		91,68	90,79	90,97	91,17	92,16	91,48	92,03	92,24		
		40%		81,02	92,04	90,82		91,20	91,46	92,80	91,89	90,80	91,78	92,08	92,40		
		60%		83,67	92,44	91,32		92,34	92,38	91,73	91,80	92,69	91,71	92,38	92,80		
		80%		84,81	92,53	91,89		91,96	92,05	93,18	92,31	92,16	92,38	92,53	93,08		
	Micro-F1	20%		79,37	92,73	91,53		93,70	92,62	91,84	92,69	93,27	93,09	92,99	93,11		
		40%		82,73	93,07	92,03		92,55	92,69					93,00	93,30		
		60%		85,27	93,39	92,48								93,31	93,70		
		80%		86,26	93,44	92,80								93,29	93,99		
IMDB	Macro-F1	20%		40,72	32,10	41,16		41,65	45,73	49,44	49,78	43,86	48,01	50,87	50,00		
		40%		45,19	31,94	44,22		50,64	52,11	46,27	49,15	51,90	51,73	50,85	52,71		
		60%		48,13	31,68	45,11		47,64	51,81	52,99	52,66	45,81	49,78	52,09	54,24		
		80%		50,35	32,06	45,15		55,28	54,17	47,59	51,71	55,91	56,39	51,60	54,38		
	Micro-F1	20%		46,38	35,28	45,65		49,88	52,29	56,44	56,09	50,99	54,61	55,01	55,73		
		40%		49,99	35,47	48,24		56,97	56,38					55,15	57,97		
		60%		52,21	35,64	49,09								56,66	58,32		
		80%		54,33	35,59	48,81								56,49	58,51		

5.2 Đường cơ sở

Chúng tôi so sánh với một số đường cơ sở hiện đại, bao gồm các phương pháp nhúng mạng (dị loại) và đồ thị dựa trên mạng nơ-ron phương pháp, để xác định hiệu quả của HAN được đề xuất. Để chuyển đổi ify về hiệu quả của sự chú ý ở cấp độ nút và cấp độ ngữ nghĩa của chúng tôi tương ứng, chúng tôi cũng thử nghiệm hai biến thể của HAN.

- DeepWalk [23]: Nhúng mạng dựa trên bước đi ngẫu nhiên phương pháp thiết kế cho các đồ thị đồng nhất. Ở đây chúng tôi bỏ qua sự không đồng nhất của các nút và thực hiện DeepWalk trên toàn bộ đồ thị không đồng nhất.
- ESim [26]: Một phương pháp nhúng đồ thị không đồng nhất mà có thể nắm bắt thông tin ngữ nghĩa từ nhiều đường dẫn meta. Tại vì rất khó để tìm kiếm trọng số của một tập hợp các đường dẫn meta, chúng tôi chỉ định trọng số học được từ HAN đến ESim.
- metapath2vec [7]: Phương pháp nhúng đồ thị không đồng nhất thực hiện đi bộ ngẫu nhiên dựa trên meta-path và sử dụng gói bỏ qua để nhúng các đồ thị không đồng nhất. Ở đây chúng tôi kiểm tra tất cả các đường dẫn meta cho metaath2vec và báo cáo hiệu suất tốt nhất.
- HERec [27]: Phương pháp nhúng đồ thị không đồng nhất thiết kế một chiến lược ràng buộc kiểu để lọc chuỗi nút và sử dụng bỏ qua gam để nhúng các đồ thị không đồng nhất. Ở đây chúng tôi kiểm tra tất cả các đường dẫn meta cho HERec và báo cáo hiệu suất tốt nhất.
- GCN [18]: Đây là một mạng tích tụ đồ thị bán giám sát được thiết kế cho các đồ thị đồng nhất. Ở đây chúng tôi kiểm tra tất cả đường dẫn meta cho GCN và báo cáo hiệu suất tốt nhất.
- GAT [35]: Nó là một mạng nơ-ron bán giám sát được coi là cơ chế chú ý trên các đồ thị thuần nhất. Đây chúng tôi kiểm tra tất cả các đường dẫn meta cho GAT và báo cáo hiệu suất tốt nhất.

- HAN: Nó là một biến thể của HAN, loại bỏ cấp độ nút sự quan tâm và gán tầm quan trọng như nhau cho từng người hàng xóm.
- HAN: Nó là một biến thể của HAN, loại bỏ sự chú ý ở cấp độ ngữ nghĩa và gán tầm quan trọng như nhau cho mỗi meta-path.
- HAN: Mạng nơ-ron đồ thị bán giám sát được đề xuất sử dụng sự chú ý ở cấp độ nút và chú ý ở cấp độ ngữ nghĩa đồng thời.

5.3 Chi tiết triển khai

Đối với HAN được đề xuất, chúng tôi khởi tạo ngẫu nhiên các tham số và tối ưu hóa mô hình với Adam [17]. Đối với HAN được đề xuất, chúng tôi đặt tỷ lệ học tập thành 0,005, tham số chính quy hóa thành 0,001, thứ nguyên của vectơ chú ý mức ngữ nghĩa q đến 128, số đầu chú ý đến 8, số chú ý bỏ qua là 0,6. Và chúng tôi sử dụng tính năng dừng sớm với độ kiên nhẫn là 100, tức là chúng tôi ngừng đào tạo nếu mất xác thực không giảm trong 100 kỳ nguyên liên tiếp. Đến làm cho các thử nghiệm của chúng tôi có thể lặp lại, chúng tôi làm cho tập dữ liệu và mã của chúng tôi công khai trên trang web⁴. Đối với GCN và GAT, chúng tôi tối ưu hóa các tham số sử dụng bộ xác thực. Đối với biểu đồ thần kinh bán giám sát mạng, bao gồm GCN, GAT và HAN, chúng tôi chia giống hệt nhau tập huấn luyện, tập xác nhận và tập kiểm tra để đảm bảo tính công bằng. Cho ngẫu nhiên các phương pháp dựa trên bước đi bao gồm DeepWalk, ESim, metapath2vec và HERec, chúng tôi đặt kích thước của số thành 5, chiều dài đi bộ là 100, số lần đi bộ trên mỗi nút đến 40, số lượng mẫu âm là 5. Để so sánh công bằng, chúng tôi đặt thứ nguyên nhúng thành 64 cho tất cả các thuật toán ở trên.

⁴<https://github.com/Jhy1993/HAN>

5.4 Phân loại

Ở đây chúng tôi sử dụng trình phân loại KNN với $k = 5$ để thực hiện phân loại nút. Vì phương sai của dữ liệu có cấu trúc đồ thị có thể khá cao, chúng tôi lặp lại quy trình 10 lần và báo cáo Macro-F1 trung bình và Micro-F1 trong Bảng 3.

Dựa trên Bảng 3, chúng ta có thể thấy rằng HAN đạt được mức tốt nhất cho mỗi công thức. Đối với phương pháp nhúng đồ thị không đồng nhất truyền thống, ESIM có thể tận dụng nhiều đường dẫn meta hoạt động tốt hơn metapath2vec. Nói chung, lập biểu đồ các phương pháp dựa trên mạng nơ-ron kết hợp cấu trúc và thông tin tính năng, ví dụ: GCN và GAT, thường hoạt động tốt hơn. Để đi sâu vào các phương pháp này, hãy so sánh đơn giản là tính trung bình so với các hàng xóm của nút, ví dụ: GCN và HAN GAT và HAN có thể cân nhắc thông tin một cách chính xác và cải thiện hiệu suất của phép nhúng đã học. So với GAT, đề xuất HAN, thiết kế cho đồ thị không đồng nhất, nắm bắt ngữ nghĩa phong phú thành công và thể hiện tính ưu việt của nó. Ngoài ra, không có chú ý cấp độ nút (HAN) hoặc chú ý cấp độ ngữ nghĩa (HAN), hiệu suất trở nên kém hơn HAN, điều này cho thấy tầm quan trọng của việc mô hình hóa cơ chế chú ý trên cả hai nút và ngữ nghĩa. Lưu ý rằng trong ACM và IMDB, HAN cải thiện kết quả sàng lọc clas đáng kể hơn trong DBLP. Chủ yếu là do APCPA quan trọng hơn nhiều so với các siêu đường dẫn còn lại. Chúng tôi sẽ giải thích hiện tượng này trong Phần 5.7 bằng cách phân tích sự chú ý ở cấp độ ngữ nghĩa.


Qua phân tích trên, chúng ta có thể thấy rằng đề xuất HAN đạt được hiệu suất tốt nhất trên tất cả các bộ dữ liệu. Kết quả quý báu rằng nó là khá quan trọng để nắm bắt tầm quan trọng của các nút và các đường dẫn meta trong phân tích đồ thị không đồng nhất.

5.5 Phân cụm


Chúng tôi cũng tiến hành nhiệm vụ phân cụm để đánh giá các lần nhúng đã học được từ các thuật toán trên. Sau khi HAN được đề xuất được đào tạo, chúng ta có thể nhận được tất cả các nút nhúng thông qua nguồn cấp dữ liệu chuyển tiếp. Ở đây chúng tôi sử dụng các KM có nghĩa là để thực hiện phân cụm nút và số lượng các cụm được đặt thành số lớp. Chúng tôi sử dụng cùng một chân lý cơ bản như trong phân loại nút. Và chúng tôi áp dụng NMI và ARI để đánh giá chất lượng của các kết quả phân cụm. Kể từ khi hoạt động của KMeans bị ảnh hưởng bởi các centroid ban đầu, chúng tôi lặp lại quá trình này trong 10 lần và báo cáo kết quả trung bình trong Bảng 4.

Như có thể thấy trong Bảng 4, chúng ta có thể thấy rằng HAN hoạt động đồng thời tốt hơn nhiều so với tất cả các đường cơ sở. Ngoài ra, lập biểu đồ mạng nơ-ron các thuật toán dựa trên thường đạt được hiệu suất tốt hơn. Bên cạnh đó, nếu không phân biệt được tầm quan trọng của các nút hoặc đường dẫn meta, thì các phương thức meta và GCN không thể hoạt động tốt. Với hướng dẫn của đa đường dẫn meta, HAN hoạt động tốt hơn đáng kể so với GCN và GAT. Mặt khác, không có sự chú ý ở cấp độ nút (HAN) hoặc sự chú ý ở cấp độ ngữ nghĩa (HAN), hiệu suất của HAN cho thấy các mức độ thoái hóa khác nhau. Nó chứng minh rằng thông qua chỉ định tầm quan trọng khác nhau cho các nút và đường dẫn meta, HAN được đề xuất có thể học cách nhúng nút có ý nghĩa hơn.

Dựa trên những phân tích trên, chúng ta có thể thấy rằng đạo cụ HAN có thể đưa ra mô tả toàn diện về biểu đồ không đồng nhất và đạt được một cái tiến đáng kể.



Hình 4: Các hàng xóm dựa trên đường meta của các giá trị chú ý phân hồi nút P831 và nút cor (Các màu khác nhau có nghĩa là khác nhau các lớp, ví dụ: màu xanh lá cây có nghĩa là Khai thác dữ liệu, màu xanh lam có nghĩa là Cơ sở dữ liệu, màu cam có nghĩa là Giao tiếp không dây).



Hình 5: Hiệu suất của một meta-path và tương ứng giá trị chú ý.

5.6 Phân tích Cơ chế Chú ý Thứ bậc

Một thuộc tính nổi bật của HAN là sự kết hợp của phân cấp cơ chế, trong đó có tầm quan trọng của các hàng xóm của nút và các đường dẫn meta được xem xét trong việc học nhúng đại diện. Nhớ lại rằng chúng ta đã học được trọng số chú ý ở cấp độ nút và trọng số chú ý ở cấp độ ngữ nghĩa. Để hiểu rõ hơn về tầm quan trọng của các hàng xóm và đường dẫn meta, chúng tôi cung cấp thông tin chi tiết phân tích về cơ chế chú ý thứ bậc.

Phân tích sự chú ý ở cấp độ nút. Như đã đề cập trước đây, đưa ra một tác vụ cụ thể, mô hình của chúng tôi có thể tìm hiểu các giá trị chú ý giữa các nút và các nước láng giềng của nó trong một đường dẫn meta. Một số hàng xóm quan trọng hữu ích cho nhiệm vụ cụ thể có xu hướng có giá trị chú ý lớn hơn. Ở đây chúng tôi lấy giấy P831 trong Tập dữ liệu ACM làm minh họa thí dụ. Đưa ra một siêu đường dẫn Giấy-Tác giả-Giấy mô tả đồng tác giả của các bài báo khác nhau, chúng tôi liệt kê đường dẫn dựa trên meta hàng xóm của giấy P831 và giá trị chú ý của chúng được thể hiện trong Hình 4. Từ Hình 4 (a), chúng ta có thể thấy rằng P831 kết nối với P699 và P133 đều thuộc về Khai thác dữ liệu; conect đến P2384 và

5Xintao Wu, Daniel Barbara, Yong Ye. Sàng lọc và diễn giải các liên kết nhiều mục Dựa trên Mô hình tuyển tính nhật ký, KDD'03
6Xintao Wu, Jianpin Fan, Kalpathi Subramanian. B-EM: một trình phân loại kết hợp bootstrap với cách tiếp cận EM để khai thác dữ liệu, KDD'02
7Daniel Barbara, Carlotta Domeniconi, James P. Rogers. Phát hiện các điểm bất thường bằng cách sử dụng thử nghiệm thống kê và truyền tải, KDD'06
8Walid G. Aref, Daniel Barbara, Padmavathi Vallabhaneni. Trie viết tay: Lập chỉ mục Mục điện tử, SIGMOD'95

Mạng chú ý đồ thị không đồng nhất WWW 2019, tháng 5 năm 2019, San Francisco, Hoa Kỳ

Bảng 4: Kết quả định lượng (%) về nhiệm vụ phân cụm nút.

Datasets	Metrics	DeepWalk	ESim	metapath2vec	HERec	GCN	GAT	HAN	HAN	HAN					
ACM	NMI	41,61	61,56	39,14	21,22	40,70	51,40	57,29	37,13	60,99	61,05				
	ARI	35,10	64,39	34,32	21,00	53,01	60,43			61,48	59,45				
DBLP	NMI	76,53		66,32	74,30	76,73	75,01	71,50		75,30	77,31	79.12			
	ARI	81,35		68,31	78,50	80,98	80,49	77,26		81.46	83.46	84,76			
IMDB	NMI	1,45		0,55	1,20	1,20	5,45	8,45		9.16	10,31	10,87			
	ARI	2,15		0,10	1,70	1,65	4,40	7,46		7.98	9.51	10.01			

P2328⁹ trong khi P2384 và P2328 đều thuộc Cơ sở dữ liệu; kết nối đến P1973¹⁰ trong khi P1973 thuộc về Giao tiếp không dây. Từ Hình 4 (b), chúng ta có thể thấy rằng giấy P831 được chú ý nhiều nhất giá trị từ sự chú ý ở cấp độ nút có nghĩa là nút đó tự phát vai trò quan trọng nhất trong việc học cách biểu diễn của nó. Đó là lý do có thể bởi vì tất cả thông tin được hỗ trợ bởi những người hàng xóm thường là được xem như một loại thông tin bổ sung. Ngoài chính nó, P699 và P133 nhận được giá trị chú ý lớn thứ hai và thứ ba. Đây là bởi vì P699 và P133 cũng thuộc về Khai thác dữ liệu và chúng có thể đóng góp đáng kể vào việc xác định lớp P831. Phần còn lại hàng xóm nhận được những giá trị chú ý nhỏ vì họ không thuộc về khai thác dữ liệu và không thể đóng góp quan trọng để xác định lớp của P831. Dựa trên những phân tích trên, chúng ta có thể thấy rằng sự chú ý ở cấp độ nút có thể cho biết sự khác biệt giữa các hàng xóm và gán trọng số cao hơn cho một số hàng xóm có ý nghĩa.

Phân tích sự chú ý ở cấp độ ngữ nghĩa. Như đã đề cập trước đây, HAN đề xuất có thể tìm hiểu tầm quan trọng của các đường dẫn meta đối với nhiệm vụ cụ thể. Để xác minh khả năng của sự chú ý ở cấp độ ngữ nghĩa, lấy DBLP và ACM làm ví dụ, chúng tôi báo cáo kết quả phân nhóm (NMI) của một meta-path và các giá trị chú ý tương ứng trong Hình 5. Rõ ràng, có một mối tương quan tích cực giữa hiệu suất của một đường dẫn meta duy nhất và giá trị chú ý của nó. Đối với DBLP, HAN cho APCPA là trọng số lớn nhất, có nghĩa là HAN coi APCPA là đường dẫn meta quan trọng nhất trong việc xác định tác giả khu vực nghiên cứu. Nó có ý nghĩa vì lĩnh vực nghiên cứu của tác giả và các hội nghị mà họ đã đệ trình có tính tương quan cao. Ví dụ, một số nhà nghiên cứu xử lý ngôn ngữ tự nhiên chủ yếu gửi giấy tờ cho ACL hoặc EMNLP, trong khi một số nhà nghiên cứu khai thác dữ liệu có thể nộp giấy tờ của họ cho KDD hoặc WWW. Trong khi đó, việc APA xác định tốt lĩnh vực nghiên cứu của tác giả là một điều khác biệt. Nếu chúng ta điều trị các đường dẫn meta này như nhau, ví dụ: HAN thì hiệu suất sẽ giảm đáng kể. Dựa trên các giá trị chú ý của mỗi meta-path, chúng tôi có thể thấy rằng APCPA siêu đường dẫn hữu ích hơn nhiều so với APA và APTPA. Vì vậy, ngay cả HAN được đề xuất có thể kết hợp chúng, APCPA vẫn đóng vai trò hàng đầu trong việc xác định lĩnh vực nghiên cứu của tác giả trong khi APA và APTPA thì không. Nó cũng giải thích tại sao hiệu suất của HAN trong DBLP có thể không đáng kể như trong ACM và IMDB. chúng tôi nhận được các kết luận tương tự về ACM. Đối với ACM, kết quả cho thấy rằng HAN mang lại trọng lượng đáng kể nhất cho PAP. Kể từ khi hiệu suất của PAP tốt hơn một chút so với PSP, vì vậy HAN có thể đạt được hiệu suất tốt bằng hoạt động trung bình đơn giản. Chúng ta có thể nhìn thấy rằng sự chú ý ở cấp độ ngữ nghĩa có thể tiết lộ sự khác biệt giữa meta-path và cân nhắc chúng một cách thỏa đáng.

5.7 Hình dung

Để so sánh trực quan hơn, chúng tôi tiến hành nhiệm vụ trực quan hóa, nhằm mục đích bố trí một biểu đồ không đồng nhất ở mức thấp không gian chiều. Cụ thể, chúng ta học cách nhúng nút dựa trên trên mô hình được đề xuất và dự án cách nhúng đã học vào một Không gian 2 chiều. Ở đây chúng tôi sử dụng t-SNE [21] để hình dung tác giả nhúng vào DBLP và tô màu các nút dựa trên khu vực nghiên cứu.


Từ Hình 6, chúng ta có thể thấy rằng GCN và GAT được thiết kế cho các đồ thị thuần nhất không hoạt động tốt. Các tác giả thuộc đến các lĩnh vực nghiên cứu khác nhau được trộn lẫn với nhau. Metapath2vec hoạt động tốt hơn nhiều so với biểu đồ thần kinh đồng nhất ở trên mạng lưới. Nó chứng tỏ rằng meta-path thích hợp (ví dụ: APCPA) có thể đóng góp đáng kể vào việc phân tích đồ thị không đồng nhất. Tuy nhiên, vì metapath2vec chỉ có thể sử dụng một meta-path xem xét, ranh giới vẫn còn mờ. Từ Hình 6, chúng tôi có thể thấy rằng hình dung của HAN peform tốt nhất. Với sự hướng dẫn của nhiều đường dẫn meta, phương pháp nhúng được học bởi HAN có sự tương đồng giữa các lớp và phân tách các tác giả trong các nghiên cứu khác nhau khu vực có ranh giới rõ ràng.

5.8 Thí nghiệm tham số


Trong phần này, chúng tôi điều tra độ nhạy của các tham số và báo cáo kết quả phân nhóm (NMI) trên tập dữ liệu ACM với nhiều các thông số trong Hình 7.

- Kích thước của lần nhúng cuối cùng Z. Đầu tiên chúng tôi kiểm tra hiệu ứng của kích thước của lần nhúng cuối cùng Z. Kết quả được hiển thị trong Hình 7 (a). Chúng ta có thể thấy điều đó với sự phát triển của việc nhúng thứ nguyên, hiệu suất tăng đầu tiên và sau đó bắt đầu giảm từ từ. Lý do là HAN cần một kích thước phù hợp để mã hóa thông tin se mantics và kích thước lớn hơn có thể giới thiệu thêm sự dư thừa.
- Thứ nguyên của véc tơ chú ý mức ngữ nghĩa q. Kể từ khi khả năng chú ý ở cấp độ ngữ nghĩa bị ảnh hưởng bởi kích thước của vectơ chú ý mức ngữ nghĩa q, chúng tôi khám phá thử nghiệm kết quả với nhiều thứ nguyên khác nhau. Kết quả được thể hiện trong Hình 7 (b). Chúng ta có thể thấy rằng hiệu suất của HAN phát triển theo chiều của vectơ chú ý cấp độ ngữ nghĩa và đạt được hiệu suất tốt nhất khi thứ nguyên của q được đặt là 128. Sau đó, hiệu suất của HAN bắt đầu thoái hóa có thể do ăn mặc quá sức.
- Số lượng đầu chú ý. Để kiểm tra tác động của sự chú ý từ nhiều phía, chúng tôi khám phá hiệu suất của HAN với số lượng đầu chú ý khác nhau. Kết quả được hiển thị trong Hình 7 (c). Lưu ý rằng sự chú ý nhiều đầu bị loại bỏ khi số của tiêu đề chú ý được đặt thành 1. Dựa trên kết quả, chúng tôi có thể tìm thấy

⁹Daniel Barbara, Tomasz Imielinski. Những người mê ngủ và nghiên cứu công việc: Chiến lược lưu vào bộ nhớ đệm trong Môi trường di động, VLDB'95
¹⁰Hector Garcia-Holina, Daniel Barbara. Chỉ phí sao chép dữ liệu, SIGCOMM'81



Hình 6: Nhúng trực quan hóa trên DBLP. Mỗi điểm chỉ ra một tác giả và màu sắc của nó chỉ ra khu vực nghiên cứu.



Hình 7: Độ nhạy tham số của HAN wrt Thứ nguyên của lần nhúng cuối cùng, Thứ nguyên của vector chú ý mức ngữ nghĩa và Số lượng chú ý đầu.

rằng số lượng đầu chú ý nhiều hơn nói chung sẽ cải thiện hiệu suất của HAN. Tuy nhiên, với việc thay đổi đầu mỗi quan tâm, hiệu suất của HAN chỉ cải thiện một chút. Trong khi đó, chúng tôi cũng nhận thấy rằng sự chú ý từ nhiều phía có thể giúp quá trình đào tạo ổn định hơn.

6 KẾT LUẬN

Trong bài báo này, chúng tôi giải quyết một số vấn đề cơ bản trong phân tích đồ thị neous không đồng nhất và đề xuất một mạng nơ ron đồ thị không đồng nhất bán giám sát chỉ dựa trên cơ chế chú ý. HAN được đề xuất có thể nắm bắt các cấu trúc phức tạp và ngữ nghĩa phong phú đằng sau đồ thị không đồng nhất. Mô hình được đề xuất thúc đẩy sự chú ý ở cấp độ nút và chú ý ở cấp độ ngữ nghĩa để tìm hiểu tầm quan trọng của các nút và đường dẫn meta tương ứng. Trong khi đó, mô hình được đề xuất sử dụng thông tin cấu trúc và thông tin tính một cách thống nhất. Kết quả thực nghiệm bao gồm phân loại và phân cụm chứng minh hiệu quả của HAN. Bằng cách phân tích các trọng số chú ý đã học bao gồm cả cấp độ nút và cấp độ ngữ nghĩa, HAN được đề xuất đã chứng minh khả năng diễn giải tốt của nó.

7 LỜI CẢM ƠN

Công trình này được hỗ trợ một phần bởi Quỹ Khoa học Tự nhiên Quốc gia Trung Quốc (số 61702296, 61772082, 61532006), Quỹ Khoa học Tự nhiên Thành phố Bắc Kinh (4182043) và Quỹ Mở CCF-Tencent.

NGƯỜI GIỚI THIỆU

[1] Dzmitry Bahdanau, Kyunghyun Cho và Yoshua Bengio. 2015. Dịch máy thần kinh bằng cách cùng nhau học cách căn chỉnh và dịch. ICLR (2015).

[2] Joan Bruna, Wojciech Zaremba, Arthur Szlam và Yann LeCun. 2013. Đặc tả mạng lưới tra và mạng kết nối cục bộ trên đồ thị. arXiv bản in trước arXiv: 1312.6203 (2013).

[3] Hongxu Chen, Hongzhi Yin, Weiqing Wang, Hao Wang, Quoc Viet Hung Nguyen, và Xue Li. 2018. PME: Nhúng số liệu dự kiến trên mạng không đồng nhất để dự đoán liên kết. Trong SIGKDD. 1177-1186.

[4] Ting Chen và Yizhou Sun. 2017. Nhúng mạng không đồng nhất có hướng dẫn tác vụ và tăng cường đường dẫn để xác định tác giả. Trong WSDM. 295-304.

[5] Peng Cui, Xiao Wang, Jian Pei và Wenwu Zhu. 2018. Một cuộc khảo sát về những mạng. Giao dịch IEEE về Kiến thức và Kỹ thuật Dữ liệu (2018).

[6] Michaël Defferrard, Xavier Bresson, và Pierre Vandergheynst. 2016. Mạng nơ-ron màu convolu trên đồ thị với khả năng lọc quang phổ cục bộ nhanh chóng. Trong NIPS. 3844-3852.

[7] Yuxiao Dong, Nitesh V Chawla, và Ananthram Swami. 2017. metapath2vec: Học đại diện có thể mở rộng cho các mạng không đồng nhất. Trong SIGKDD. 135- 144.

[8] Yujie Fan, Shifu Hou, Yiming Zhang, Yanfang Ye và Melih Abdulhayoglu. 2018. Phần mềm đọc hai Gotcha-sly !: Scorpion một hệ thống phát hiện phần mềm độc hại dựa trên metagraph2vec. Trong SIGKDD. 253-262.

[9] Tao-yang Fu, Wang-Chien Lee, và Zhen Lei. 2017. HIN2Vec: Khám phá các đường dẫn Meta trong Mạng Thông tin Không đồng nhất để Học Đại diện. Trong CIKM. 1797-1806.

[10] Marco Gori, Gabriele Monfardini và Franco Scarselli. 2005. Một mô hình mới cho học trong miền đồ thị. Trong IJCNN, Vol. 2. 729-734.

[11] Palash Goyal và Emilio Ferrara. 2017. Kỹ thuật, ứng dụng và hiệu suất nhúng đồ thị: Một cuộc khảo sát. arXiv bản in trước arXiv: 1705.02801 (2017).

[12] Aditya Grover và Jure Leskovec. 2016. node2vec: Học tính năng có thể mở rộng cho các mạng. Trong SIGKDD. 855-864.

[13] Will Hamilton, Payal Bajaj, Marinka Zitnik, Dan Jurafsky và Jure Leskovec. 2018. Những câu truy vấn logic vào đồ thị kiến thức. Những tiến bộ trong hệ thống xử lý thông tin thần kinh . 2030-2041.

[14] William L. Hamilton, Rex Ying và Jure Leskovec. 2017. Đại diện quy nạp trên Đồ thị Lớn. Trong NIPS. 1024-1034.

[15] Xiaotian Han, Chuan Shi, Senzhang Wang, S Yu Philip, và Li Song. 2018. Cấp độ khía cạnh lọc cộng tác sâu qua mạng thông tin không đồng nhất .. Trong IJCAI. 3393-3399.

[16] Binbin Hu, Chuan Shi, Wayne Xin Zhao, và Philip S Yu. 2018. Tận dụng bối cảnh dựa trên Meta-path cho Đề xuất Top-N với Mô hình đồng chú ý thần kinh. Trong SIGKDD. 1531-1540.

[17] Diederik P Kingma và Jimmy Ba. 2015. Adam: Một phương pháp tối ưu hóa ngẫu nhiên . ICLR (2015).

[18] Thomas N. Kipf và Max Welling. 2017. Phân loại bán giám sát với Đồ thị Mạng lưới. Trong ICLR.

[19] Xiang Li, Yao Wu, Martin Ester, Ben Kao, Xin Wang, và Yudian Zheng. 2017. Phân cụm bán giám sát trong các mạng thông tin không đồng nhất được quy. Trong WWW. 1621-1629.

[20] Yujia Li, Daniel Tarlow, Marc Brockschmidt và Richard Zemel. 2016. Gated đồ thị trình tự mạng nơ ron. ICLR (2016).

[21] Laurens Van Der Maaten và Geoffrey Hinton. 2008. Trục quan hóa dữ liệu bằng t-SNE. Tạp chí Nghiên cứu Máy học 9, 2605 (2008), 2579-2605.

[22] Mingdong Ou, Peng Cui, Jian Pei, Ziwei Zhang và Wenwu Zhu. 2016. Bảo tồn độ nhảy số liệu không trung bình những đồ thị. Trong SIGKDD. 1105-1114.

[23] Bryan Perozzi, Rami Al-Rfou và Steven Skiena. 2014. Deepwalk: Trục tuyến học các đại diện xã hội. Trong SIGKDD. 701-710.

[24] Franco Scarselli, Marco Gori, Ah Chung Tsoi, Markus Hagenbuchner và Gabriele Monfardini. 2009. Mô hình mạng nơron đồ thị. Giao dịch IEEE trên Mạng thần kinh 20, 1 (2009), 61-80.

[25] Michael Schlichtkrull, Thomas N Kipf, Peter Bloem, Rianne van den Berg, Ivan Titov và Max Welling. 2018. Mô hình hóa dữ liệu quan hệ với mạng chập đồ thị . Trong Hội nghị Web Ngữ nghĩa Châu Âu. Springer, 593-607.

[26] Jingbo Shang, Meng Qu, Jialu Liu, Lance M. Kaplan, Jiawei Han, và Jian Peng. 2016. Những có hướng dẫn siêu đường dẫn để tìm kiếm sự giống nhau trong mạng thông tin không đồng nhất quy mô lớn. CoRR abs / 1610.09769 (2016).

[27] Chuan Shi, Binbin Hu, Xin Zhao, và Philip Yu. 2018. Đề xuất Những mạng thông tin không đồng nhất. Giao dịch IEEE trên Kiến thức và

Kỹ thuật dữ liệu (2018).

[28] Chuan Shi, Yitong Li, Jiawei Zhang, Yizhou Sun, và Philip S. Yu. 2017. Khảo sát về Phân tích Mạng Thông tin Không đồng nhất. Giao dịch IEEE về Kiến thức và Kỹ thuật Dữ liệu 29 (2017), 17-37.

[29] Yu Shi, Qi Zhu, Fang Guo, Chao Zhang, và Jiawei Han. 2018. Dễ dàng học những đing bằng cách phiên mã toàn diện các mạng thông tin không đồng nhất. Trong SIGKDD. ACM, 2190-2199.

[30] Lichao Sun, Lifang He, Zhipeng Huang, Bokai Cao, Congying Xia, Xiaokai Wei, và S Yu Philip. 2018. Những chung meta-path và meta-graph cho các mạng thông tin không đồng nhất. Trong Hội nghị Quốc tế IEEE về Tri thức lớn (ICBK) năm 2018. 131-138.

[31] Yizhou Sun và Jiawei Han. 2013. Khai thác mạng thông tin không đồng nhất: một cách tiếp cận phân tích cấu trúc. Bản tin Khám phá Acm Sigkdd 14, 2 (2013), 20-28.

[32] Yizhou Sun, Jiawei Han, Xifeng Yan, Philip S Yu và Tianyi Wu. 2011. Pathsim: Tìm kiếm độ tương tự top-k dựa trên đường dẫn meta trong các mạng thông tin không đồng nhất. VLDB 4, 11 (2011), 992-1003.

[33] Jian Tang, Meng Qu, Mingzhe Wang, Ming Zhang, Jun Yan và Qiaozhu Mei. 2015. Đồng: Những mạng thông tin quy mô lớn. Trong WWW. 1067-1077.

[34] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser và Illia Polosukhin. 2017. Chú ý là tất cả những gì bạn cần. Trong NIPS. 5998-6008.

[35] Petar Velicǎkovi c, Guillem Cucurull, Arantxa Casanova, Adriana Romero, Pietro Liò và Yoshua Bengio. 2018. Mạng chú ý đồ thị. ICLR (2018).

[36] Daixin Wang, Peng Cui và Wenwu Zhu. 2016. Cấu trúc mạng sâu những đing. Trong SIGKDD. 1225-1234.

[37] Xiao Wang, Peng Cui, Jing Wang, Jian Pei, Wenwu Zhu và Shiqiang Yang. 2017. Những mạng bảo tồn cộng đồng .. Trong AAAI. 203-209.

[38] Kelvin Xu, Jimmy Ba, Ryan Kiros, Kyunghyun Cho, Aaron Courville, Ruslan Salakhudinov, Rich Zemel và Yoshua Bengio. 2015. Hiện thị, tham dự và kẻ: Tạo chú thích hình ảnh thần kinh với sự chú ý trực quan. Trong ICML. 2048-2057.